

1. 排列熵

给定单变量时间序列 $\{y_k\}_{k=1}^M$ ，引入嵌入维数 d ，时间延迟 τ 有 $Y_l^{d,\tau} = \{y_l, y_{l+\tau}, \dots, y_{l+(d-1)\tau}\}$ for $l=1, 2, \dots, M-(d-1)\tau$ 。共 $L=M-(d-1)\tau$ 个向量，间隔为 τ ，长度为 d 。 $L=M-(d-1)\tau$ 个向量一一映射到一个 ordinal pattern，一共有 $d!$ 可能的排列 $\{\pi_j^{d,\tau}\}_{j=1}^{d!}$ 可用 Π 表示。根据 Shannon entropy 的形式，排列熵的计算公式为：

$$H(p_{PE}) = - \sum_{j: \pi_j^{d,\tau} \in \Pi} p(\pi_j^{d,\tau}) \ln p(\pi_j^{d,\tau}) = - \sum p_{PE} \ln p_{PE}$$

$p(\pi_j^{d,\tau})$ 为

$$p(\pi_j^{d,\tau}) = p_{MPE} = \frac{\|l: l \leq L, \text{type}(Y_l^{d,\tau}) = \pi_j^{d,\tau}\|}{L}$$

where $\text{type}(\cdot)$ denotes the map from pattern space to symbol space and $\|\cdot\|$ denotes the cardinality of a set.

例子：时间序列 $x = \{3, 2, 5, 8, 9, 6, 1\}$ ，取 $d=3$ 、 $\tau=1$ 。相当于 $M=7, L=7-(3-1)*1=5$ 个向量一一映射到一个 ordinal pattern (motif)。

第一个 $(x_1, x_2, x_3) = (3, 2, 5)$ 映射到 ordinal pattern (213)，因为 $x_2 < x_1 < x_3$ ，第二个三维向量时 $(x_1, x_2, x_3) = (2, 5, 8)$ 映射到 (123)，第三个三维向量时 $(x_1, x_2, x_3) = (5, 8, 9)$ 映射到 (123)，第四个三维向量时 $(x_1, x_2, x_3) = (8, 9, 6)$ 映射到 (231)，第五个三维向量时 $(x_1, x_2, x_3) = (9, 6, 1)$ 映射到 (321)。

然后一共有 6 (即 $3!$) 种可能的排列 (123 的排列组合)，然后可以计算出排列的概率分布： $p(123)=2/5$ 、 $p(132)=0$ 、 $p(213)=1/5$ 、 $p(231)=1/5$ 、 $p(312)=0$ 、 $p(321)=1/5$ 。

排列熵根据香农熵的形式求得： $s[p] = -(2/5) \log(2/5) - 3(1/5) \log(1/5) = 1.3322$

2. 多尺度排列熵

给定时间序列 $\{x_i\}_i^N$ 和 尺度 s ，粗粒化后的时间序列

$$y_k^{(s)} = \frac{1}{s} \sum_{i=(k-1)s+1}^{ks} x_i$$

其实就是每 s 项进行平均。对于粗粒化后时间序列再计算排列熵。步骤根据排列熵步骤即可。




Fig. 1 Schematic diagram of the coarse-graining procedure when the scale are 2 and 3, respectively

例 子 : $x = \{3, 2, 5, 8, 9, 6, 1, 3\}$ ，粗 粒 化 接 上 ， 取 $s=2$, $y = \{(3+2)/2, (5+8)/2, (9+6)/3, (1+3)/2\} = \{2.5, 6.5, 7.5, 2\}$ ，取 $d=2$, $\tau=1$ 。相当于 $M=4$, $L=4-(2-1)*1=3$ 个向量一一映射到一个 ordinal pattern (motif)。第一个 $(x_1, x_2) = (2.5, 6.5)$ 映射到 ordinal pattern (12)，第二个 $(x_1, x_2) = (6.5, 7.5)$ 映射到 (12) 第三个 $(x_1, x_2) = (7.5, 2)$ 映射到 (21)

同样一共有 2 (即 $2!$) 种可能的排列: $p(\pi_1) = p(12) = 2/3$, $p(\pi_2) = p(21) = 1/3$.

排列熵根据香农熵的形式求得: $s[p] = -(1/3) \log(1/3) - (2/3) \log(2/3) = 0.6365$

3. 多尺度多变量排列熵

给定多变量 (m 个变量) 长度为 N 的时间序列 $X = \{x_{i,t}\}_{i=1, \dots, m}^{t=1, \dots, N}$ ，粗粒化后的 m 维时

间序列 $Y_k^s = (y_{i,k}^s)_{i=1, \dots, m}^{k=1, \dots, M}$ 由以下公式获得:

$$y_{i,k}^s = \frac{1}{s} \sum_{t=(k-1)s+1}^{ks} x_{i,t}$$

s 尺度因子 and $1 \leq k \leq M = \frac{N}{s}$. 同样引入嵌入维数和延迟有

$Z_{i,l}^{d,\tau,s} = \{y_{i,l}^s, y_{i,l+\tau}^s, \dots, y_{i,l+(d-1)\tau}^s\}$ for $l=1, 2, \dots, M-(d-1)\tau$ ，对每个变量映射，The

relative frequencies $p_{i,j}^s$ are defined as:

$$p_{i,j}^s = \frac{\|l: l \leq L, \text{type}(Z_{i,l}^{d,\tau,s}) = \pi_j^{d,\tau}\|}{L} = \frac{\sum_{l \leq L} 1_{u:\text{type}(u)=\pi_j^{d,\tau}}(Z_{i,l}^{d,\tau,s})}{\sum_{l \leq L} 1_{u:\text{type}(u)=\Pi}(Z_{i,l}^{d,\tau,s})}$$

其中 $L = M - (d-1)\tau$ and $j = 1, \dots, n, n = d!$. $p_{i,j}^s$ are the entries of a matrix

$P_{s(m,n)} = \{p_{i,j}^s\}$, 它反映了粗粒度多元时间序列中 motifs 的分布, Here,

$\sum_{i=1}^m \sum_{j=1}^n p_{i,j}^s = m$. 根据算法将原始的多元时间序列转化为时间相关矩阵, 其中可

以清楚地绘制相关统计量和熵。同时, 描述 motif 分布的边缘相对频率可以计

算为 $P_{mvMPE} = p_{\cdot,j}^s = \sum_{i=1}^m p_{i,j}^s$ 除以 m , for $j = 1, \dots, d!$, 多元多尺度排列熵计算公式:

$$H(p_{mvMPE}) = -\sum_{j=1}^{d!} p_{\cdot,j}^s \ln p_{\cdot,j}^s = -\sum p_{mvMPE} \ln p_{mvMPE}$$

注: 添加多变量后其实也是按照每个变量求 motif 的概率, 组成矩阵, 然后多变量最后的 p 就是对矩阵按列求平均, 列和除以变量个数。最后运用 Shannon 形式带入。

例子: 给定 2 维时间序列: $x = \{3, 2, 5, 8, 9, 6, 1;$

$2, 4, 6, 8, 5, 7, 3\}$

$s=2$ 粗粒化后: $y = \{(3+2)/2, (5+8)/2, (9+6)/2$

$(2+4)/2, (6+8)/2, (5+7)/2\} =$

$\{2.5, 6.5, 7.5;$

$3, 7, 6\}$

取 $d=2, \tau=1$ 可得出每个 Z 的映射

$Z_{11} = (2.5, 6.5) \text{ -- (12)} \quad Z_{12} = (6.5, 7.5) \text{ --- (12)}$

$Z_{21} (3, 7) \text{ -- (12)} \quad Z_{22} = (7, 6) \text{ -- (21)}$

$$p_{11}=p(12)=1 \quad p_{12}=p(21)=0$$

$$p_{21}=p(12)=0.5 \quad p_{22}=p(21)=0.5 \quad \text{全部都是按变量求}$$

$$P=\{1, 0;$$

$$0.5, 0.5\}$$

$$p_{mv}mPE=\{(1+0.5)/2, (0+0.5)/2\}=\{0.75, 0.25\}$$

$$s[p]=-(0.75)\log(0.75)-(0.25)\log(0.25)=0.5623$$

4. 熵值标准化:

如果 $S[P]=0$ ，我们就能够确定地预测哪一种可能的结果，这是完全确定的，我的概率是由 p 给出的，在这种情况下，我们对概率分布描述的底层过程的知识是最大的。当均匀分布时，所有结果出现可能性一样，我们无法根据概率预测出哪种结果出现更有可能，这是完全不确定的，此时是 $s[p]$ 最大为 S_{max} ，我们的知识是最小的。

$$S_{max}=-(m!)(1/m!)\log(1/m!)=\log(m!)$$

$$\text{标准化的熵 } H=s[p]/S_{max}=s[p]/\log(m!)$$

熵捕捉了时间序列的不确定性和无序性

对嵌入维数和时间延迟的选择问题，嵌入维数决定了可能的排列个数 ($d!$ 个) 和每个 motif 的维数，因此太小或太大都不好，时间延迟为 1 是连续的取，当 τ 大于 1 时，组成排列的值被非连续地取，从而在不同的时间分辨率下映射系统的动力学。在 Permutation entropy: a natural complexity measure for time series 一文中 Bandt 和 Pompe 在 $[3, 7]$ 范围内考虑嵌入维数 d 。至于其他参数的选项，他们特别建议 $\tau=1$ 的时间延迟 参考这篇文章: Parameter selection for permutation entropy measurements。

